

Relative Häufigkeiten, Prognosebereiche und das $1/\sqrt{n}$ -Gesetz

Ziel der GeoGebra-Datei

Die GeoGebra-Datei verbindet zentrale Sichtweisen der Stochastik in einer gemeinsamen Darstellung. Ausgehend von einem Modellparameter p wird eine konkrete Realisation einer Münzwurfserie erzeugt. Dargestellt wird die laufende relative Häufigkeit


$$H_i = \frac{X_1 + \dots + X_i}{i}.$$

Dabei ist X_j die Indikatorvariable für einen Treffer im j -ten Versuch.

Die Datei soll nicht nur ein schönes Bild erzeugen, sondern ein *stochastisches Lesebild* bereitstellen. Sichtbar werden:

- eine einzelne Realisation der relativen Häufigkeiten,
- Prognosebereiche für mögliche Werte von H_n ,
- Verteilungen der Zufallsgrößen H_{n_1} und H_{n_2} ,
- die Verringerung der typischen Schwankungsbreite bei wachsendem n .

1. Die Trajektorie: eine einzelne Realisation



Die blaue Kurve zeigt eine einzelne Realisation der laufenden relativen Häufigkeiten. Für jeden Zeitpunkt i wird die bisherige relative Häufigkeit

$$H_i = \frac{X_1 + \dots + X_i}{i}$$

dargestellt.


Die gestrichelte waagerechte Linie zeigt den Modellparameter p . Im Beispiel ist $p = 0,5$.

Wichtig ist die folgende Klarstellung: Die relative Häufigkeit nähert sich nicht in dem Sinne immer mehr an p an, dass die Kurve monoton oder gleichmäßig auf p zuläuft. Auch bei großen Stichprobenumfängen kann es weiterhin Schwankungen geben. Was kleiner wird, ist die typische Schwankungsbreite der relativen Häufigkeit.

Die Trajektorie zeigt also:

Eine einzelne Realisation schwankt um den Modellparameter p .

2. Prognosebereiche für mögliche Werte von H_n



Ein Prognosebereich beschreibt, welche Werte der Zufallsgröße H_n unter dem Modellparameter p typischerweise zu erwarten sind.

Dabei ist p im Modell fest vorgegeben. Zufällig ist nicht p , sondern die zukünftige relative Häufigkeit H_n .

Für große n kann man näherungsweise schreiben:

$$H_n \approx p \pm 1,96 \sqrt{\frac{p(1-p)}{n}}.$$

Genauer gesagt handelt es sich bei einem Prognosebereich um eine hochwahrscheinliche Menge möglicher Werte der Zufallsgröße H_n . Da H_n nur diskrete Werte der Form

$$0, \frac{1}{n}, \frac{2}{n}, \dots, \frac{n}{n}$$

annehmen kann, ist die Intervallschreibweise eine schulisch gut handhabbare Darstellung. Im Unterricht kann man formulieren:

Bei vielen Wiederholungen werden die Werte von H_n unter diesem Modell mit hoher Wahrscheinlichkeit in diesen Bereich fallen.


Fachlich präziser ist also nicht:

Prognoseintervall für p ,

sondern:

Prognosebereich für mögliche Werte von H_n unter dem Modellparameter p .

3. Verteilungen von H_{n_1} und H_{n_2}



Die eingeblendeten Punktwolken zeigen viele mögliche Werte der Zufallsgrößen H_{n_1} und H_{n_2} . Die roten Punkte markieren die Werte der gerade sichtbaren Trajektorie zu den Zeitpunkten n_1 und n_2 .

Damit werden zwei Perspektiven verbunden:

- Die blaue Kurve zeigt eine konkrete Realisation.

- Die Punktwolken zeigen, welche anderen Werte unter demselben Modell möglich gewesen wären.

Der rote Punkt muss dabei nicht Teil der grünen Punktwolke sein. Er gehört zur aktuell dargestellten Trajektorie. Die Punktwolke zeigt unabhängig davon viele mögliche Realisationen derselben Zufallsgröße.

4. Das $1/\sqrt{n}$ -Gesetz

Für die relative Häufigkeit gilt

$$\sigma(H_n) = \sqrt{\frac{p(1-p)}{n}}.$$

Wird der Stichprobenumfang vervierfacht, also $n_2 = 4n_1$, dann erhält man

$$\sigma(H_{n_2}) = \sqrt{\frac{p(1-p)}{4n_1}} = \frac{1}{2} \sqrt{\frac{p(1-p)}{n_1}} = \frac{1}{2} \sigma(H_{n_1}).$$

Die typische Schwankungsbreite halbiert sich also erst bei vierfachem Stichprobenumfang. Das ist eine zentrale Einsicht:

Mehr Daten stabilisieren relative Häufigkeiten, aber die Genauigkeit wächst nur mit der Wurzel des Stichprobenumfangs.

Didaktische Einordnung

Die Datei zeigt nicht nur eine Simulation, sondern verbindet zentrale Begriffe der Stochastik:

- Modellparameter,
- Zufallsgröße,
- Realisation,
- empirische Verteilung,
- Prognosebereich,
- Schwankungsbreite,
- $1/\sqrt{n}$ -Gesetz.

Der Mehrwert des GeoGebra-Einsatzes liegt darin, dass diese Begriffe nicht isoliert auftreten. Sie werden in einem gemeinsamen Bild miteinander verknüpft.

1 Anhang

Modellwahrscheinlichkeit $\rightarrow$ Zufallsgröße der relativen Häufigkeit $\rightarrow$ beobachtete Realisation

Begriffliche Klärung: Was wird eigentlich prognostiziert?

Merksatz: Streuen kann die Verteilung einer Zufallsgröße oder eine Gesamtheit vieler Realisationen, nicht aber eine einzelne Realisation.

Ist p im Modell vorgegeben oder als Modellparameter angenommen, so beschreibt ein Prognosebereich eine hochwahrscheinliche Menge möglicher Werte von $H_n(A)$.

Die GeoGebra-Datei macht diese Unterscheidung sichtbar: Die blaue Trajektorie zeigt eine einzelne Realisation der laufenden relativen Häufigkeiten. Die Punktwolken zeigen viele mögliche Realisationen von $H_{n_1}(A)$ und $H_{n_2}(A)$. Die Prognosebereiche beziehen sich nicht auf mögliche Werte von p , sondern auf mögliche Werte dieser Zufallsgrößen unter dem Modellparameter p .

Merksatz: Streuen kann die Verteilung einer Zufallsgröße oder eine Gesamtheit vieler Realisationen, nicht aber eine einzelne Realisation.

Die Wahrscheinlichkeit $p = P(A)$ ist ein Modellparameter. Sie sagt nicht eine konkrete relative Häufigkeit voraus, sondern ermöglicht probabilistische Aussagen über die Zufallsgröße $H_n(A)$. Ein beobachteter Wert $h_n(A)$ ist eine Realisation dieser Zufallsgröße.